

Sequence Alignment and Machine Learning for SARS-CoV-2 Spike Variant Classification

Andrew Tedjapratama¹³⁵²³¹⁴⁸, Nathanael Rachmat¹³⁵²³¹⁴², Brian Ricardo Tamin¹³⁵²³¹²⁶, Theo Kurniady¹³⁵²³¹⁵⁴

Program Studi Teknik Informatika - IF3211 Komputasi Domain Spesifik

Sekolah Teknik Elektro dan Informatika - Komputasi (STEI-K)

Institut Teknologi Bandung, Bandung, Indonesia

Abstract—Makalah ini menyajikan pendekatan machine learning untuk mengklasifikasikan varian SARS-CoV-2 (Alpha, Delta, Omicron) berdasarkan fitur yang diekstraksi dari protein sequence alignment spike protein-nya. Kami mengimplementasikan algoritma Needleman-Wunsch dan Smith-Waterman dari awal dengan affine gap penalties dan skoring BLOSUM62. Empat fitur utama—sequence length, BLOSUM score, mismatches, dan gap count—diekstraksi dari global alignments terhadap spike protein referensi Wuhan-Hu-1. Model Random Forest dan Support Vector Machine mencapai akurasi klasifikasi tinggi (98.32%) dengan 5-fold cross-validation. Analisis kami menyoroti signifikansi biologis dari gap count sebagai fitur paling berpengaruh, yang merefleksikan pola mutasi yang berbeda antar varian. Sistem yang dikembangkan juga menyediakan interpretasi biologis melalui deteksi mutation marker, sehingga dapat digunakan untuk membantu prediksi varian dan analisis mutasi secara cepat.

Index Terms—SARS-CoV-2, coronavirus, variant classification, sequence alignment, Needleman-Wunsch, Smith-Waterman, machine learning, spike protein, BLOSUM62

I. PENDAHULUAN

A. Latar Belakang

SARS-CoV-2, virus penyebab pandemi COVID-19, terus mengalami evolusi yang menghasilkan berbagai varian dengan tingkat penularan, virulensi, dan kemampuan immune evasion yang bervariasi [1]. Memahami dan mengklasifikasikan varian-varian ini secara cepat sangat penting untuk surveilans kesehatan masyarakat dan respons pandemi yang efektif. Di antara protein virus, spike (S) protein menjadi perhatian khusus karena perannya yang krusial dalam memediasi masuknya virus ke sel inang dengan berikatan pada reseptor Angiotensin-converting enzyme 2 (ACE2). Mutasi pada spike protein, terutama di dalam Receptor Binding Domain (RBD), dapat secara signifikan mengubah sifat fungsionalnya, yang mengarah pada karakteristik berbeda yang diamati pada varian seperti Alpha, Delta, dan Omicron.

Metode komputasi, khususnya sequence alignment dan machine learning, menawarkan alat yang ampuh untuk menganalisis variasi genetik ini. Protein sequence alignment memungkinkan identifikasi daerah yang lestari (conserved regions) dan situs yang berbeda (divergent sites), memberikan wawasan tentang hubungan evolusi dan perubahan fungsional. Model machine learning kemudian dapat memanfaatkan fitur yang berasal dari alignment ini untuk mengklasifikasikan varian berdasarkan tanda mutasi uniknya.

B. Rumusan Masalah

Penelitian ini berfokus pada klasifikasi varian SARS-CoV-2 (Alpha, Delta, dan Omicron) menggunakan fitur yang diekstraksi dari protein sequence alignment spike protein-nya. Oleh karena itu, rumusan masalah utama dalam penelitian ini adalah: Sejauh mana fitur yang diperoleh dari protein sequence alignment mampu membedakan varian SARS-CoV-2 (Alpha, Delta, dan Omicron) menggunakan model machine learning?

C. Tujuan Penelitian

Tujuan utama dari penelitian ini adalah untuk mengembangkan dan mengevaluasi sistem klasifikasi yang robust yang mampu membedakan antara varian-varian kunci tersebut. Kontribusi utama dari pekerjaan ini meliputi:

- Implementasi algoritma Needleman-Wunsch dan Smith-Waterman dari awal dengan affine gap penalties dan skoring BLOSUM62 untuk protein sequence alignment.
- Pengembangan pipeline feature extraction yang menghasilkan fitur-fitur relevan secara biologis (length, BLOSUM score, mismatches, gap count) dari global alignments.
- Evaluasi model Random Forest dan Support Vector Machine untuk klasifikasi varian, menunjukkan akurasi tinggi dan kinerja yang robust.
- Interpretasi biologis dari feature importance, khususnya menyoroti peran gap count dalam membedakan varian.
- Deteksi mutation marker biologis untuk meningkatkan interpretabilitas hasil klasifikasi.

II. LANDASAN TEORI

A. SARS-CoV-2 dan Spike Protein

SARS-CoV-2 adalah virus RNA beruntai tunggal berpolaritas positif. Spike protein-nya adalah glikoprotein trimerik yang ditemukan di permukaan virus, esensial untuk masuknya virus ke dalam sel inang. Subunit S1 dari spike protein mengandung Receptor Binding Domain (RBD), yang berinteraksi langsung dengan reseptor ACE2 manusia. Mutasi dalam spike protein, terutama di RBD, dapat mengubah transmisibilitas virus, kemampuan immune evasion, dan efektivitas vaksin. Sebagai contoh, mutasi N501Y, yang ada pada varian Alpha dan Omicron, diketahui meningkatkan afinitas ikatan ACE2. Mutasi L452R dan T478K pada RBD varian Delta terkait dengan peningkatan transmisibilitas, sementara varian Omicron

menunjukkan kluster mutasi (K417N, E484A, Q493R, Q498R, Y505H) di RBD-nya, berkontribusi pada immune escape yang signifikan.

Sequence similarity mencerminkan hubungan evolusi antar protein. Sequence alignment adalah teknik bioinformatika fundamental yang digunakan untuk mengidentifikasi daerah kesamaan yang mungkin merupakan konsekuensi dari hubungan fungsional, struktural, atau evolusi antara sekuens biologis. Dengan melakukan alignment protein sequence, kita dapat menunjukkan perubahan asam amino spesifik (substitutions, insertions, deletions) yang menjadi ciri khas varian SARS-CoV-2 yang berbeda.

B. Sequence Alignment

Sequence alignment adalah teknik fundamental dalam bioinformatika yang digunakan untuk mengidentifikasi daerah kesamaan antara dua atau lebih sekuens biologis, seperti DNA, RNA, atau protein. Kesamaan ini dapat mengindikasikan hubungan fungsional, struktural, atau evolusi. Dalam konteks protein, alignment membantu dalam memahami perubahan asam amino yang terjadi akibat mutasi. Baik algoritma global alignment maupun local alignment diimplementasikan dari awal menggunakan Python. Algoritma-algoritma ini memanfaatkan dynamic programming untuk menemukan alignment optimal antara dua sekuens.

Dalam konteks proyek ini, sequence alignment digunakan untuk membandingkan spike protein dari sequence uji terhadap sequence referensi Wuhan-Hu-1. Hasil alignment memungkinkan identifikasi substitusi, insersi, dan delesi yang menjadi karakteristik biologis masing-masing varian.

C. Needleman-Wunsch (NW)

Algoritma Needleman-Wunsch [2] adalah algoritma global alignment yang menemukan alignment optimal antara dua sekuens secara keseluruhan. Algoritma ini menggunakan model affine gap penalty, yang membedakan antara pembukaan gap dan perpanjangan gap yang sudah ada. Algoritma ini menggunakan tiga matriks: M (match/mismatch), X (gap pada sekuens 1), dan Y (gap pada sekuens 2). Relasi rekurensi untuk matriks-matriks ini dirancang untuk memaksimalkan skor alignment. Kompleksitas waktu dan ruang dari algoritma Needleman-Wunsch adalah $O(mn)$, di mana m dan n adalah panjang kedua sekuens.

Pada penelitian ini, hasil Needleman-Wunsch digunakan sebagai dasar ekstraksi fitur machine learning karena menghasilkan alignment global terhadap seluruh spike protein.

D. Smith-Waterman (SW)

Algoritma Smith-Waterman [3] adalah algoritma local alignment yang mengidentifikasi subsequences paling mirip dalam dua sekuens yang lebih besar. Mirip dengan Needleman-Wunsch, algoritma ini juga menggunakan affine gap penalty. Perbedaan utamanya adalah skor negatif dalam matriks dynamic programming diatur menjadi nol, dan traceback dimulai dari sel dengan skor tertinggi, berhenti ketika skor nol ditemui. Hal ini memungkinkan algoritma untuk menemukan daerah

yang sangat lestari (conserved regions) tanpa memberikan penalti pada daerah yang tidak mirip di luar local alignment. Kompleksitas waktu dan ruangnya juga $O(mn)$.

Meskipun tidak digunakan sebagai sumber fitur klasifikasi, hasil Smith-Waterman ditampilkan untuk menunjukkan perbedaan alignment lokal dan global serta membantu interpretasi biologis sequence yang lebih divergen.

E. Machine Learning

Machine learning adalah cabang dari kecerdasan buatan yang memungkinkan sistem untuk belajar dari data dan membuat prediksi atau keputusan tanpa diprogram secara eksplisit. Dalam penelitian ini, dua model machine learning digunakan untuk klasifikasi varian: Random Forest dan Support Vector Machine (SVM). Kedua model ini dilatih menggunakan empat fitur yang telah diekstraksi.

1) Model:

- **Random Forest:** Metode ensemble learning yang bekerja dengan membangun banyak decision tree selama proses pelatihan dan menghasilkan prediksi berdasarkan voting mayoritas untuk klasifikasi atau rata-rata prediksi untuk regresi. Pada penelitian ini digunakan parameter `n_estimators = 100`.
- **Support Vector Machine (SVM):** Metode supervised learning yang digunakan untuk tugas klasifikasi dan regresi. Model ini membangun hyperplane optimal untuk memisahkan data antar kelas. Pada penelitian ini digunakan kernel RBF (*Radial Basis Function*) untuk menangani hubungan non-linear antar fitur.

Model-model tersebut diimplementasikan menggunakan library scikit-learn [4].

III. METODOLOGI

Metodologi penelitian ini melibatkan beberapa langkah kunci: persiapan dataset, protein sequence alignment, feature extraction, pelatihan dan evaluasi model machine learning, serta pengembangan web application. Pipeline sistem secara keseluruhan diilustrasikan pada Fig 1.

A. Dataset

Dataset terdiri dari sekuens spike protein untuk varian Alpha, Delta, dan Omicron dari SARS-CoV-2, yang bersumber dari NCBI Virus. Spike protein Wuhan-Hu-1 (NCBI accession: YP_009724390.1) berfungsi sebagai sekuens referensi. Awalnya, dataset berisi 200 sekuens untuk setiap varian. Langkah filtering diterapkan untuk mempertahankan hanya sekuens dengan panjang antara 1200 dan 1300 asam amino, menghasilkan dataset akhir sebanyak 595 sekuens (tanpa outlier). Filtering ini dilakukan untuk menghilangkan sequence yang tidak lengkap (partial sequence) sehingga hasil alignment dan fitur yang dihasilkan lebih representatif.

Dataset disimpan dalam format FASTA, yaitu format standar penyimpanan sequence biologis yang terdiri dari header diawali karakter ">" dan diikuti urutan asam amino. Format ini umum digunakan pada basis data biologis seperti NCBI dan UniProt.




Fig. 1. Diagram pipeline sistem: dari sekuens input hingga prediksi varian dan interpretasi mutasi.

Distribusi panjang sekuens untuk setiap varian sebelum filtering dirangkum pada Tabel I.

TABLE I
STATISTIK DATASET (PRA-PEMBERSIHAN, N=200 PER KELAS)

Varian	Panjang Rata-rata	Std	Min	Max
Alpha	1270.0	0.98	1258	1273
Delta	1264.3	40.4	946	1273
Omicron	1269.4	2.89	1238	1273

B. Alignment Protein Sequence

Dalam penelitian ini, algoritma global dan local protein sequence alignment diimplementasikan dari awal menggunakan Python. Algoritma Needleman-Wunsch dan Smith-Waterman, yang dijelaskan secara rinci pada subbab Needleman-Wunsch dan Smith-Waterman di Landasan Teori, digunakan untuk menemukan alignment optimal antara sekuens spike protein varian SARS-CoV-2 dengan sekuens referensi Wuhan-Hu-1. Implementasi ini memanfaatkan dynamic programming untuk efisiensi komputasi.




Fig. 2. Distribusi jumlah sampel per varian setelah filtering 595 sekuens total (~200 per kelas)




Fig. 3. Perbandingan output alignment NW (global) dan SW (local) pada sekuens spike MERS-CoV terhadap referensi Wuhan-Hu-1. NW menghasilkan alignment sepanjang keseluruhan sekuens dengan gap di berbagai posisi, sedangkan SW hanya mengembalikan segmen lokal dengan skor tertinggi — menunjukkan perbedaan mendasar strategi kedua algoritma.

C. Skema Penilaian

Untuk penilaian substitusi asam amino, digunakan matriks substitusi BLOSUM62 [5]. Matriks BLOSUM (Blocks Substitution Matrix) diturunkan dari substitusi yang diamati dalam blok-blok lestari dari sekuens protein yang telah di-align, sehingga secara biologis lebih bermakna daripada skoring match/mismatch sederhana. BLOSUM62 sangat cocok untuk meng-align sekuens dengan divergensi evolusi moderat. Affine gap penalties ditetapkan sebagai berikut: gap open = -10 dan gap extend = -0.5. Library Biopython [6] digunakan untuk memuat matriks BLOSUM62.

D. Ekstraksi Fitur

Dari global alignment Needleman-Wunsch setiap sekuens spike protein terhadap referensi Wuhan-Hu-1, empat fitur diekstraksi untuk klasifikasi machine learning:

- **length:** Panjang sekuens query dalam asam amino.
- **score_blosum:** Skor alignment Needleman-Wunsch menggunakan BLOSUM62 dan affine gap penalties.

- **mismatches:** Jumlah total substitusi asam amino (karakter yang tidak cocok, tidak termasuk gap) dalam global alignment.
- **gap_count:** Jumlah total posisi gap (insersi atau delesi) dalam global alignment.

Penting untuk dicatat bahwa metrik `identity_pct` dan `gap_openings` dihitung dan ditampilkan pada web application sebagai informasi tambahan, tetapi tidak digunakan sebagai fitur masukan pada model machine learning.

E. Deteksi Mutation Marker

Mutation marker spesifik dideteksi setelah melakukan alignment Needleman-Wunsch terhadap sekuens referensi Wuhan. Marker-marker ini, berdasarkan posisi spike protein yang diindeks 1, sangat penting untuk interpretasi biologis tetapi tidak digunakan sebagai fitur machine learning. Marker yang terdeteksi dan varian terkaitnya tercantum dalam Tabel II.

TABLE II
MUTATION MARKER YANG TERDETEKSI DAN VARIAN TERKAIT

Marker	Varian	Posisi
N501Y	Alpha, Omicron	501
L452R	Delta	452
T478K	Delta	478
K417N	Omicron	417
E484A	Omicron	484
Q493R	Omicron	493
Q498R	Omicron	498
Y505H	Omicron	505

F. Interpretasi Biologis Mutation Marker

Mutasi L452R dan T478K merupakan mutation marker khas varian Delta yang diketahui berkaitan dengan peningkatan transmissibility virus. Kedua mutasi tersebut berkontribusi terhadap peningkatan kemampuan infeksi SARS-CoV-2 dan menjadi salah satu karakteristik utama varian Delta.

Mutasi N501Y ditemukan pada varian Alpha dan Omicron. Mutasi ini diketahui meningkatkan afinitas pengikatan spike protein terhadap reseptor ACE2 pada sel inang, sehingga dapat meningkatkan efisiensi infeksi virus.

Sementara itu, mutasi K417N, E484A, Q493R, Q498R, dan Y505H membentuk kluster mutasi pada Receptor Binding Domain (RBD) varian Omicron. Kombinasi mutasi tersebut berkontribusi terhadap kemampuan immune escape, yaitu kemampuan virus untuk menghindari pengenalan oleh antibodi yang terbentuk akibat infeksi sebelumnya maupun vaksinasi.

G. Model Machine Learning

1) *Validasi:* Kinerja model dievaluasi menggunakan 5-fold cross-validation. Teknik ini membantu dalam menilai bagaimana hasil analisis statistik akan digeneralisasi ke dataset independen.

IV. HASIL DAN DISKUSI

Sistem klasifikasi kami mencapai akurasi tinggi dalam membedakan antara varian SARS-CoV-2 Alpha, Delta, dan Omicron. Baik model Random Forest maupun SVM menunjukkan kinerja yang sangat baik.




Fig. 4. Tampilan hasil prediksi pada web application. Sistem menampilkan varian yang diprediksi, tingkat kepercayaan model, probabilitas tiap kelas, serta mutation marker yang terdeteksi untuk membantu interpretasi biologis hasil klasifikasi.

A. Kinerja Klasifikasi

Tabel III merangkum akurasi keseluruhan kedua model pada test set.

TABLE III
AKURASI MODEL PADA TEST SET

Model	Akurasi
Random Forest	98.32%
SVM	98.32%

Hasil cross-validation lebih lanjut mengkonfirmasi kekokohan model, seperti yang ditunjukkan pada Tabel IV.

TABLE IV
HASIL 5-FOLD CROSS-VALIDATION

Model	Akurasi Rata-rata	Std Dev
Random Forest	94.62%	2.53%
SVM	94.29%	2.22%

B. Feature Importance

Analisis feature importance untuk model Random Forest mengungkapkan bahwa `gap_count` adalah fitur yang paling signifikan, diikuti oleh `length`, `score_blosom`, dan `mismatches`. Hal ini disajikan dalam Tabel V dan secara visual pada Gambar 5.

TABLE V
FEATURE IMPORTANCE RANDOM FOREST

Fitur	Importance
length	0.3062
score_blosom	0.1223
mismatches	0.0853
gap_count	0.4861

C. Confusion Matrix

Confusion matrix untuk model Random Forest pada test set, yang ditunjukkan pada Tabel VI dan Fig 6, mengindikasikan kinerja klasifikasi yang sangat baik dengan misklasifikasi yang minimal.




Fig. 5. Feature importance dari model Random Forest. Fitur `gap_count` memiliki kontribusi terbesar dalam proses klasifikasi, diikuti oleh `length`, `score_blosum`, dan `mismatches`.

TABLE VI
CONFUSION MATRIX (RANDOM FOREST, TEST SET)

Aktual / Prediksi	Alpha	Delta	Omicron
Alpha	40	0	0
Delta	0	38	1
Omicron	1	0	39

D. Interpretasi Biologis dari Gap Count

Dominasi `gap_count` sebagai fitur terpenting (0.4861) memiliki signifikansi biologis. Gap dalam protein sequence alignment biasanya merepresentasikan insersi atau delesi (indels) asam amino. Varian SARS-CoV-2 yang berbeda dicirikan tidak hanya oleh point mutations (substitusi) tetapi juga oleh pola indel yang berbeda dalam spike protein-nya. Misalnya, varian Setiap varian memiliki pola insersi/delesi yang konsisten pada posisi-posisi tertentu terhadap referensi Wuhan-Hu-1, sehingga jumlah gap menjadi sinyal diskriminatif yang kuat meskipun secara absolut nilainya kecil, terutama di daerah yang krusial untuk immune evasion dan pengikatan ACE2. Indels ini dapat secara drastis mengubah struktur dan fungsi protein, menyebabkan perubahan fenotipik yang signifikan. Oleh karena itu, `gap_count` secara efektif menangkap variasi struktural skala besar ini yang sangat diskriminatif antar

varian, menjadikannya fitur yang kuat untuk klasifikasi.

V. IMPLEMENTASI SISTEM

Sistem klasifikasi varian SARS-CoV-2 yang telah dikembangkan diimplementasikan sebagai web application menggunakan BioPython, NumPy, FastAPI, dan React. Aplikasi ini dirancang untuk menyediakan antarmuka yang intuitif bagi pengguna untuk melakukan prediksi varian secara cepat dan interpretasi mutasi. Pengguna dapat mengunggah sekuens protein spike dalam format FASTA, dan sistem akan memprosesnya menggunakan pipeline yang telah dijelaskan dalam metodologi. Hasil prediksi varian (Alpha, Delta, atau Omicron) akan ditampilkan bersama dengan informasi mutation marker yang terdeteksi dan interpretasi biologisnya. Implementasi ini bertujuan untuk memberikan alat praktis bagi peneliti dan profesional kesehatan untuk memantau evolusi virus dan mendukung upaya surveilans.

VI. KESIMPULAN

Penelitian ini berhasil menunjukkan efektivitas penggunaan fitur protein sequence alignment dengan machine learning untuk mengklasifikasikan varian SARS-CoV-2. Implementasi algoritma Needleman-Wunsch dan Smith-Waterman kami, ditambah dengan skoring BLOSUM62, menjadi dasar untuk mengekstraksi fitur-fitur diskriminatif. Model Random Forest dan SVM mencapai akurasi tinggi, dengan `gap_count` teridentifikasi sebagai indikator biologis kritis untuk diferensiasi varian. Web application yang dikembangkan menawarkan alat praktis untuk analisis varian secara cepat.

Untuk pekerjaan di masa mendatang, kami berencana untuk memperluas dataset agar mencakup varian SARS-CoV-2 yang lebih baru dan yang sedang muncul untuk meningkatkan generalisasi model. Investigasi lebih lanjut mengenai teknik feature engineering lainnya dan model machine learning yang lebih canggih juga dapat menghasilkan peningkatan. Selain itu, eksplorasi integrasi informasi struktural dari spike protein dapat memberikan wawasan biologis yang lebih dalam dan berpotensi meningkatkan akurasi klasifikasi.

UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih kepada dosen pengampu mata kuliah IF3211 Komputasi Domain Spesifik atas bimbingan, arahan, serta materi yang telah diberikan selama proses pembelajaran dan pelaksanaan tugas ini. Penulis juga mengucapkan terima kasih kepada Prodi Teknik Informatika dan Sekolah Teknik Elektro dan Informatika (STEI), Institut Teknologi Bandung, yang telah menyediakan lingkungan akademik yang mendukung proses penelitian dan pengembangan sistem.

Selain itu, penulis menyampaikan apresiasi kepada seluruh pihak yang telah memberikan dukungan, masukan, dan bantuan selama proses pengumpulan data, pengembangan aplikasi, pelatihan model machine learning, serta penyusunan laporan penelitian ini.




Fig. 6. Ringkasan hasil analisis dataset dan evaluasi model. Visualisasi mencakup confusion matrix Random Forest, feature importance, distribusi dataset antar varian, serta statistik panjang sekuens setelah proses preprocessing.

LAMPIRAN

Repositori Proyek

Source code, dataset preprocessing, implementasi algoritma alignment, model machine learning, dan web application yang dikembangkan dalam penelitian ini dapat diakses melalui repositori GitHub berikut:

<https://github.com/Nanaa05/sars-classifier>

Video Presentasi dan Demo

Video yang mencakup presentasi penelitian, penjelasan metodologi, hasil eksperimen, serta demonstrasi penggunaan sistem dapat diakses melalui:

<https://www.youtube.com/watch?v=XDIcT8VVHk>

REFERENCES

- [1] F. Wu, S. Zhao, B. Yu, Y.-M. Chen, W. Wang, Z.-G. Song, Y. Hu, Z.-W. Tao, J.-H. Tian, Y.-Y. Pei *et al.*, "A new coronavirus associated with human respiratory disease in china," *Nature*, vol. 579, no. 7798, pp. 265–269, 2020.
- [2] S. B. Needleman and C. D. Wunsch, "A general method applicable to the search for similarities in the amino acid sequence of two proteins," *Journal of Molecular Biology*, vol. 48, no. 3, pp. 443–453, 1970.
- [3] T. F. Smith and M. S. Waterman, "Identification of common molecular subsequences," *Journal of Molecular Biology*, vol. 147, no. 1, pp. 195–197, 1981.
- [4] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg *et al.*, "Scikit-learn: Machine learning in python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [5] S. Henikoff and J. G. Henikoff, "Amino acid substitution matrices from protein blocks," *Proceedings of the National Academy of Sciences*, vol. 89, no. 22, pp. 10915–10919, 1992.
- [6] P. J. A. Cock, T. Antao, J. T. Chang, B. A. Chapman, C. J. Cox, A. Dalke, I. Friedberg, T. Hamelryck, F. Kauff, B. Wilczynski, and M. J. L. de Hoon, "Biopython: Freely available python tools for computational molecular biology and bioinformatics," *Bioinformatics*, vol. 25, no. 11, pp. 1422–1423, 2009.